Fiche de préparation — Validation orale

DiaCare Analytics — Équipe 3 (4CCE19, ESPRIT) · Membre 2 : Asma Abdellatif · Sujet : prédire la durée de séjour

1. Objectif métier

La durée de séjour détermine l'occupation des lits, le planning du personnel et le coût d'une hospitalisation. Si l'hôpital estime dès l'admission la durée de chaque séjour, il peut anticiper le nombre de lits occupés et ajuster à l'avance ses effectifs et ses admissions programmées.

- **Objectif :** prévoir l'occupation des lits pour planifier le personnel et les admissions, en estimant la durée de séjour de chaque patient.
- **Critère de réussite :** erreur moyenne de 1 à 2 jours par patient (durée entre 1 et 14 jours) ; le total de jours-lits prédit sur le test doit rester proche du total réel.
- **Contrainte :** à l'admission, seules les informations connues à ce moment sont utilisées. Le modèle sert à la planification globale, pas à une décision sur un patient isolé — les erreurs individuelles se compensent sur l'ensemble des patients.

2. Objectif data science

Élément	Description
Type de problème	Régression supervisée
Variable cible	time_in_hospital (1 à 14 jours, moyenne ≈ 4,3)
À exclure	readmitted (info future). num_lab_procedures et num_medications ne sont connues qu'en fin de séjour → gardées seulement dans la version « après séjour »
Métriques	MAE, RMSE, R^2, et écart entre total de jours prédits et total réel
Modèles (étape suivante)	Régression linéaire, Ridge, forêt aléatoire, gradient boosting

3. Méthode de préparation des données

3.1 Nettoyage — point de départ

- Reprise du df_clean du Membre 1 : 69 970 patients, 43 colonnes — un séjour par patient, patients décédés retirés, valeurs manquantes traitées.
- Visualisation : histogramme de time_in_hospital (moyenne 4,27 j, médiane 3 j) ; histogrammes et boxplots des variables numériques.
- Constat : number_outpatient, number_emergency et number_inpatient sont très asymétriques (beaucoup de 0, quelques valeurs extrêmes).

3.2 Transformation

- **Découpage 80/20** entraînement/test — fait avant tout calcul ajusté, pour éviter toute fuite d'information du test vers l'entraînement.
- **Plafonnement au 99e percentile** (calculé sur l'entraînement) des variables de comptage, plutôt que suppression des lignes — seuils obtenus : num_lab_procedures ≤ 85, num_procedures ≤ 6, num_medications ≤ 44, number_outpatient ≤ 4, number_emergency ≤ 2, number_inpatient ≤ 3, number_diagnoses ≤ 9.
- **Transformation log(1+x)** sur number_outpatient, number_emergency, number_inpatient et num_medications, pour réduire l'asymétrie.
- **Encodage :** 0/1 pour les variables binaires (gender, change, diabetesMed) ; diagnostics (diag_1/2/3, ~700 codes CIM-9 chacun) regroupés en grandes catégories cliniques (Circulatoire, Respiratoire, Digestif, Diabète,

Blessure, Musculo-squelettique, Génito-urinaire, Néoplasme, Autre) puis one-hot ; medical_specialty (71 valeurs) regroupée en top 10 + Autre + Inconnu puis one-hot.

- **StandardScaler** ajusté sur le jeu d'entraînement uniquement, puis appliqué au test.

3.3 Sélection de variables

- Matrice de corrélation de chaque variable préparée avec time_in_hospital (sur train).
- Seuil : on garde les variables avec |corrélation| > 0,1.
- Si deux variables retenues sont corrélées entre elles à plus de 0,8, une seule est gardée (la plus corrélée à la cible) — aucune paire n'a dépassé ce seuil ici.

Variable	Corrélation avec time_in_hospital
log_num_medications (scalée)	0,44
num_lab_procedures (scalée)	0,33
number_diagnoses (scalée)	0,23
num_procedures (scalée)	0,18
change (0/1)	0,11

3.4 Deux versions du jeu de variables

Version	Variables retenues	Nb
Admission (sans infos de fin de séjour)	number_diagnoses, num_procedures, change	3
Après séjour (toutes les variables)	log_num_medications, num_lab_procedures, number_diagnoses, num_procedures, change	5

À retenir / à dire clairement à la prof

- La méthode suit exactement la consigne : split avant calcul, clipping au 99e percentile, log1p sur les variables asymétriques, encodage binaire + one-hot par catégories, scaler fit sur train seul, puis sélection par corrélation (seuil 0,1 et filtre de redondance à 0,8).
- Avec ce seuil, seules 3 (admission) et 5 (après séjour) variables dépassent 0,1 de corrélation individuelle — les catégories one-hot de diagnostics/spécialité n'atteignent pas ce seuil seules (la plus forte est diag_2 = Diabète, à -0,096, juste sous le seuil).
- num_lab_procedures et num_medications ne sont utilisées que dans la version « après séjour », conformément à la contrainte métier (pas connues à l'admission).

4. Modélisation

Quatre modèles sont entraînés sur chacune des deux versions de variables (Admission / Après séjour), soit 8 modèles au total, tous évalués sur le même jeu de test (20 %, jamais vu pendant l'entraînement).

Modèle	Principe
Régression linéaire	Relation linéaire globale entre les variables et time_in_hospital — référence simple.
Ridge	Régression linéaire régularisée : pénalise les coefficients trop grands, utile si des variables restent corrélées entre elles.
Forêt aléatoire	Combinaison de nombreux arbres de décision — capture des relations non linéaires.
Gradient boosting	Arbres construits un par un, chacun corrigeant les erreurs du précédent.

Hyperparamètres utilisés : Ridge (alpha = 1,0) ; forêt aléatoire (200 arbres, profondeur max 8) ; gradient boosting (200 arbres, profondeur max 3, taux d'apprentissage 0,05) — réglages raisonnables de départ, pas encore optimisés finement.

5. Évaluation

Résultats sur le jeu de test (20 %), triés par MAE croissante dans chaque version :

Version	Modèle	MAE (j)	RMSE (j)	R2
Admission	Gradient boosting	2,14	2,75	0,11
Admission	Forêt aléatoire	2,14	2,75	0,11
Admission	Régression linéaire	2,16	2,78	0,10
Admission	Ridge	2,16	2,78	0,10
Après séjour	Gradient boosting	1,85	2,43	0,31
Après séjour	Forêt aléatoire	1,85	2,44	0,30
Après séjour	Régression linéaire	1,94	2,52	0,25
Après séjour	Ridge	1,94	2,52	0,25

Résultat principal

- Le **gradient boosting** est le meilleur modèle sur les deux versions (légèrement devant la forêt aléatoire).
- Version « Après séjour » : MAE ≈ 1,85 jour — **dans l'objectif métier** (1 à 2 jours d'erreur).
- Version « Admission » : MAE ≈ 2,14 jours — légèrement au-dessus de l'objectif, logique puisqu'elle dispose de moins d'informations (pas de num_lab_procedures ni num_medications).
- R^2 modeste (0,10 à 0,31) : le modèle explique une partie limitée de la variation de la durée de séjour — cohérent avec le petit nombre de variables retenues (3 et 5) après le filtrage par corrélation.

6. Questions probables de la prof — réponses courtes

Q — Pourquoi exclure readmitted ?

R — C'est une information connue seulement après la sortie du patient (fuite d'information / data leakage) : elle ne doit jamais servir à prédire la durée de séjour.

Q — Pourquoi deux versions (admission / après séjour) ?

R — Contrainte métier : à l'admission, on ne connaît pas encore num_lab_procedures ni num_medications, qui ne sont mesurées qu'en fin de séjour. La version « admission » respecte ce que le modèle peut réellement utiliser en pratique.

Q — Pourquoi découper 80/20 avant le clipping et le scaler ?

R — Pour éviter toute fuite d'information du test vers l'entraînement : les seuils (percentile 99, moyenne/écart-type du scaler) doivent être calculés uniquement sur les données d'entraînement, puis appliqués tels quels au test.

Q — Pourquoi plafonner les valeurs extrêmes plutôt que supprimer les lignes ?

R — Pour ne pas perdre de patients ni réduire l'échantillon : le plafonnement au 99e percentile limite l'effet des valeurs extrêmes tout en gardant toutes les lignes.

Q — Pourquoi une transformation log(1+x) sur certaines variables ?

R — number_outpatient, number_emergency, number_inpatient et num_medications ont beaucoup de zéros et une distribution très asymétrique ; log(1+x) gère le zéro (contrairement à log simple) et rend la distribution plus régulière.

Q — Pourquoi regrouper les diagnostics en catégories plutôt qu'un one-hot direct ?

R — diag_1, diag_2 et diag_3 ont chacun environ 700 codes CIM-9 distincts : un one-hot direct créerait des centaines de colonnes presque vides. Le regroupement en grandes catégories cliniques (Circulatoire, Respiratoire, Diabète, etc.) est l'approche standard pour ce type de données.

Q — Pourquoi un seuil de corrélation à 0,1 et de redondance à 0,8 ?

R — Le seuil de 0,1 écarte les variables sans lien linéaire perceptible avec la cible ; le seuil de 0,8 entre deux variables retenues sert à éviter la redondance (colinéarité) en ne gardant que celle la plus liée à la cible.

Q — Pourquoi seulement 3 et 5 variables retenues, et pas plus ?

R — Avec le seuil de 0,1 appliqué à ce df_clean, seules les variables numériques (nombre de médicaments, d'actes de labo, de diagnostics, de procédures) et « change » dépassent ce seuil. Les catégories de diagnostics/spécialité s'en approchent (jusqu'à -0,096) mais ne le franchissent pas individuellement. Je peux resserrer ou assouplir ce seuil si on veut un jeu de variables plus large.

Q — Pourquoi tester 4 modèles différents plutôt qu'un seul ?

R — Pour comparer un modèle simple et interprétable (régression linéaire/Ridge) à des modèles plus flexibles (forêt aléatoire, gradient boosting) qui captent des relations non linéaires. On choisit ensuite le meilleur compromis précision/simplicité plutôt que de supposer a priori lequel sera le meilleur.

Q — Quel est le meilleur modèle, et l'objectif métier est-il atteint ?

R — Le gradient boosting est le plus précis sur les deux versions. En « après séjour », son erreur moyenne (MAE ≈ 1,85 j) atteint l'objectif métier de 1 à 2 jours. En « admission », l'erreur (≈ 2,14 j) est légèrement au-dessus, ce qui est cohérent : cette version dispose de moins d'informations sur le patient.

Q — Pourquoi le R2 est-il aussi faible (0,10 à 0,31) ?

R — Le R2 mesure la part de variation de la durée de séjour expliquée par le modèle. Avec seulement 3 à 5 variables retenues après le filtrage par corrélation, le modèle ne capture qu'une partie des facteurs qui influencent réellement la durée de séjour — un R2 modeste est attendu ici, et la MAE reste le critère le plus parlant pour l'objectif métier (jours d'erreur par patient).

Astuce pour l'oral : annonce toujours le **pourquoi** avant le **comment** — « je dois faire X parce que Y » plutôt que réciter la liste des étapes. Garde ce document sous les yeux, mais explique avec tes mots.